

LEMANS SCHOOL OF AI | SESSION 4.03

SESSION D'INITIATION AUX

# GENERATIVE ADVERSARIAL NETWORKS

JEUDI 15 OCTOBRE 2020 | 18H30 | LE MANS INNOVATION


LEMANS  
SCHOOL OF AI

ARTIFICIAL INTELLIGENCE STUDY GROUP MADE BY DOERS FOR DOERS IN LE MANS



**NVIDIA**  @nvidia · 7 oct.

NVIDIA Maxine will be making an appearance on [@BBCClick](#) with [@thisisFoxx](#) this weekend! Can't wait that long? Get a sneak peek of how this new [#AI](#) platform transforms video conferencing in the [#GTC20](#) keynote: [nvda.ws/3jEH5Zn](https://nvidia.ws/3jEH5Zn)



Sender

Keyframe



Webcam



Keypoint Extraction



Receiver

Keyframe




Keypoints



Output

NVIDIA AI Video Compression



# Sommaire

1/ intro (5 min)

2/ exemples d'application (15 min)

3/ comment ça marche (25 min)

4/ un programme exemple (15 min)

5/ quelques considérations (15min)

**intro**



La technologie **GAN** est introduite en 2014

par **Ian Goodfellow** ( OpenAI Institute -> Google -> Apple (directeur ML) )




# de quoi s'agit-il ?

- **GAN** = type de modèle de DL
- la particularité : compétition entre deux réseaux de neurones :  
un **générateur** contre un **discriminateur**.



Feedback transmis au Générateur :

*Tu n'as pas su tromper le Discriminateur sur tel design*



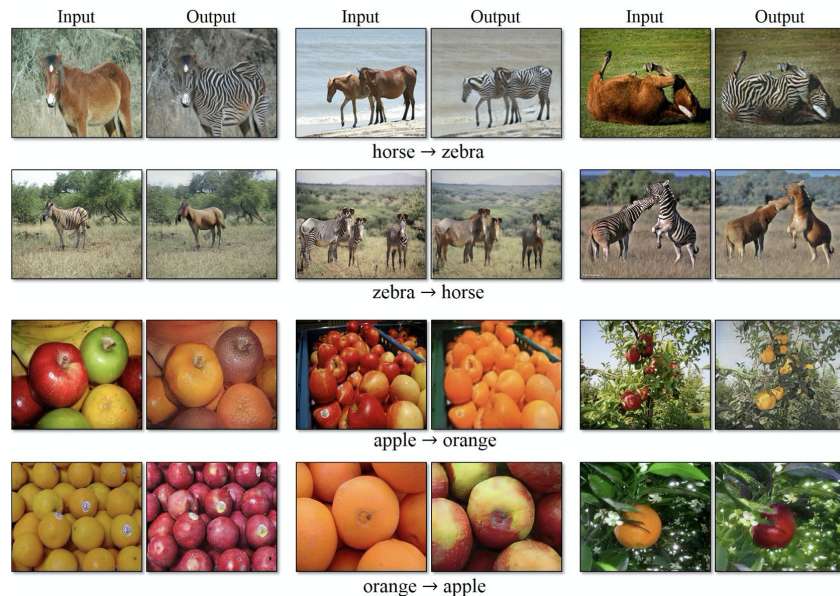

**quelques  
exemples  
d'application**

# StyleGAN : génération d'images




<https://thispersondoesnotexist.com/>

# CycleGAN : transfert d'images/vidéos



# GauGAN - NVIDIA





Input




Output



Input



Output



# 3D GAN

<http://3dgan.csail.mit.edu>




Figure 1: The generator of 3D Generative Adversarial Networks (3D-GAN)



Figure 2: Shapes synthesized by 3D-GAN

# Entreprise utilisant les GANs



Nouvelle génération  
de Photoshop



Augmentation de  
données



Superresolution



Filtres sur les images



Génération de texte




vidéo






retirer le bruit d'une image






<https://colourise.sg/>




**comment ça  
marche**


# Réseaux à convolution (discriminateur)



# Entraînement du discriminateur

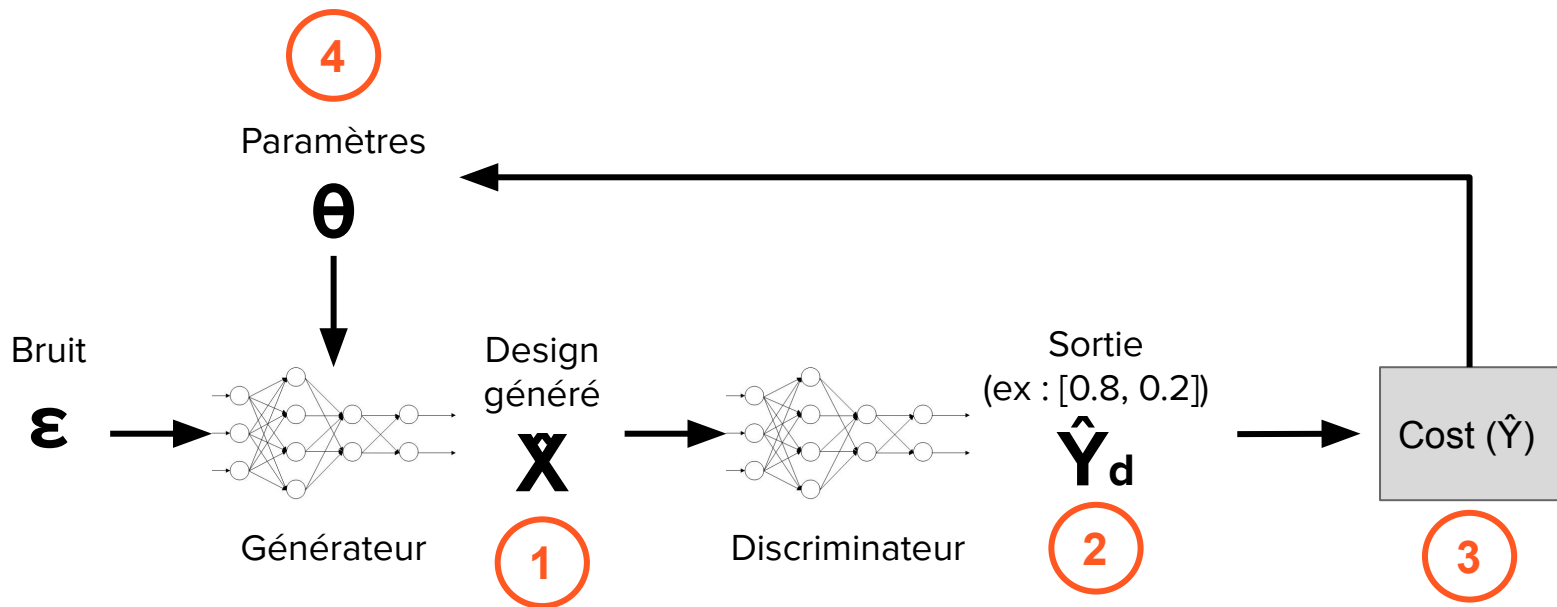


# Réseaux à déconvolution (générateur)






# Entraînement du générateur



Objectif pour :

- le Générateur :  $\hat{Y}_d = [1, 0]$
- le Discriminateur :  $\hat{Y}_d = [0, 1]$

# Upsampling techniques (le plus proche voisin)



# Upsampling techniques (déconvolution)

10	20
15	7

INPUT  
(2x2)

\*

1	1
2	2

FILTER  
(2x2)

=

$10*1$	$10*1+20*1$	$20*1$
$10*2+15*1$	$10*2+15*1+20*2+7*1$	$20*2+7*1$
$15*2$	$15*2+7*2$	$7*2$

# Binary cross-entropy cost function

$$J(\theta) = -\frac{1}{m} \sum_{i=1}^m \left[ \overset{\text{real } y^{(i)}=1}{y^{(i)} \log h(x^{(i)}, \theta)} + \overset{\text{fake } y^{(i)}=0}{(1 - y^{(i)}) \log(1 - h(x^{(i)}, \theta))} \right]$$

Prediction
Label
Features
Parameters

$h(x^{(i)}, \theta)$	$\log h(x^{(i)}, \theta)$	$\log(1 - h(x^{(i)}, \theta))$
$\sim 0$	$-\infty$	$\sim 0$
$\sim 1$	$\sim 0$	$-\infty$


Objectif pour :

- le Générateur :  $J(\theta)$  plus grand possible
- le Discriminateur :  $J(\theta)$  plus proche de 0 possible

**un programme  
exemple**

# mon premier GAN

- avec Keras, tensorflow
- dataset de chiffres manuscrits de MNIST
- objectif : générer une image synthétique d'un chiffre



# le générateur

entrée :

*100-dimensional noise*

sortie :

*vector of the size 784*

*(28x28 the original size*

*of the images)*

```
class Generator(keras.Model):

    def __init__(self, random_noise_size = 100):
        super().__init__(name='generator')
        #layers
        self.input_layer = keras.layers.Dense(units = random_noise_size)
        self.dense_1 = keras.layers.Dense(units = 128)
        self.leaky_1 = keras.layers.LeakyReLU(alpha = 0.01)
        self.dense_2 = keras.layers.Dense(units = 128)
        self.leaky_2 = keras.layers.LeakyReLU(alpha = 0.01)
        self.dense_3 = keras.layers.Dense(units = 256)
        self.leaky_3 = keras.layers.LeakyReLU(alpha = 0.01)
        self.output_layer = keras.layers.Dense(units=784, activation = "tanh")

    def call(self, input_tensor):
        ## Definition of Forward Pass
        x = self.input_layer(input_tensor)
        x = self.dense_1(x)
        x = self.leaky_1(x)
        x = self.dense_2(x)
        x = self.leaky_2(x)
        x = self.dense_3(x)
        x = self.leaky_3(x)
        return self.output_layer(x)

    def generate_noise(self, batch_size, random_noise_size):
        return np.random.uniform(-1,1, size = (batch_size, random_noise_size))
```

# fonction de coût pour le générateur

```
cross_entropy = tf.keras.losses.BinaryCrossentropy(from_logits = True)
```


```
def generator_objective(dx_of_gx):  
    # Labels are true here because generator thinks he produces real images.  
    return cross_entropy(tf.ones_like(dx_of_gx), dx_of_gx)
```



# Génération sans entraînement

```
generator = Generator()  
fake_image = generator(np.random.uniform(-1,1, size =(1,100)))  
fake_image = tf.reshape(fake_image, shape = (28,28))  
plt.imshow(fake_image, cmap = "gray")
```

<matplotlib.image.AxesImage at 0x7f65e2a7e198>



# le discrimi- -nateur

entrée :

*784-dimensional*

*vector (28\*28 = 784)*

sortie :

*1 neurone*

*a fake or a real image*

```
class Discriminator(keras.Model):
    def __init__(self):
        super().__init__(name = "discriminator")

        #Layers
        self.input_layer = keras.layers.Dense(units = 784)
        self.dense_1 = keras.layers.Dense(units = 128)
        self.leaky_1 = keras.layers.LeakyReLU(alpha = 0.01)
        self.dense_2 = keras.layers.Dense(units = 128)
        self.leaky_2 = keras.layers.LeakyReLU(alpha = 0.01)
        self.dense_3 = keras.layers.Dense(units = 128)
        self.leaky_3 = keras.layers.LeakyReLU(alpha = 0.01)

        # This neuron tells us if the input is fake or real
        self.logits = keras.layers.Dense(units = 1)
    def call(self, input_tensor):
        ## Definition of Forward Pass
        x = self.input_layer(input_tensor)
        x = self.dense_1(x)
        x = self.leaky_1(x)
        x = self.leaky_2(x)
        x = self.leaky_3(x)
        x = self.leaky_3(x)
        x = self.logits(x)
        return x
```

# fonction de coût pour le discriminateur

```
def discriminator_objective(d_x, g_z, smoothing_factor = 0.9):  
    """  
    d_x = real output  
    g_z = fake output  
    """  
  
    # If we feed the discriminator with real images,  
    # we assume they all are the right pictures --> Because of that label == 1  
    real_loss = cross_entropy(tf.ones_like(d_x) * smoothing_factor, d_x)  
  
    # Each noise we feed in are fakes image --> Because of that labels are 0  
    fake_loss = cross_entropy(tf.zeros_like(g_z), g_z)  
  
    total_loss = real_loss + fake_loss  
  
    return total_loss
```

remarque : smoothing\_factor is to avoid overfitting

# Entrainement

```
BATCH_SIZE = 256
BUFFER_SIZE = 60000
EPOCHES = 300
```

```
@tf.function()
def training_step(generator: Discriminator, discriminator: Discriminator, images: np.ndarray, k: int = 1, batch_size = 32):
    for _ in range(k):
        with tf.GradientTape() as gen_tape, tf.GradientTape() as disc_tape:
            noise = generator.generate_noise(batch_size, 100)
            g_z = generator(noise)
            d_x_true = discriminator(images) # Trainable?
            d_x_fake = discriminator(g_z) # dx_of_gx


            discriminator_loss = discriminator_objective(d_x_true, d_x_fake)
            # Adjusting Gradient of Discriminator
            gradients_of_discriminator = disc_tape.gradient(discriminator_loss, discriminator.trainable_variables)
            discriminator_optimizer.apply_gradients(zip(gradients_of_discriminator, discriminator.trainable_variables)) # Takes a list of gradient and variables pairs

            generator_loss = generator_objective(d_x_fake)
            # Adjusting Gradient of Generator
            gradients_of_generator = gen_tape.gradient(generator_loss, generator.trainable_variables)
            generator_optimizer.apply_gradients(zip(gradients_of_generator, generator.trainable_variables))
```

# résultat

```
fake_image = generator(np.random.uniform(-1,1, size = (1, 100)))  
plt.imshow(tf.reshape(fake_image, shape = (28,28)), cmap="gray")
```

<matplotlib.image.AxesImage at 0x7f65e0f7db70>

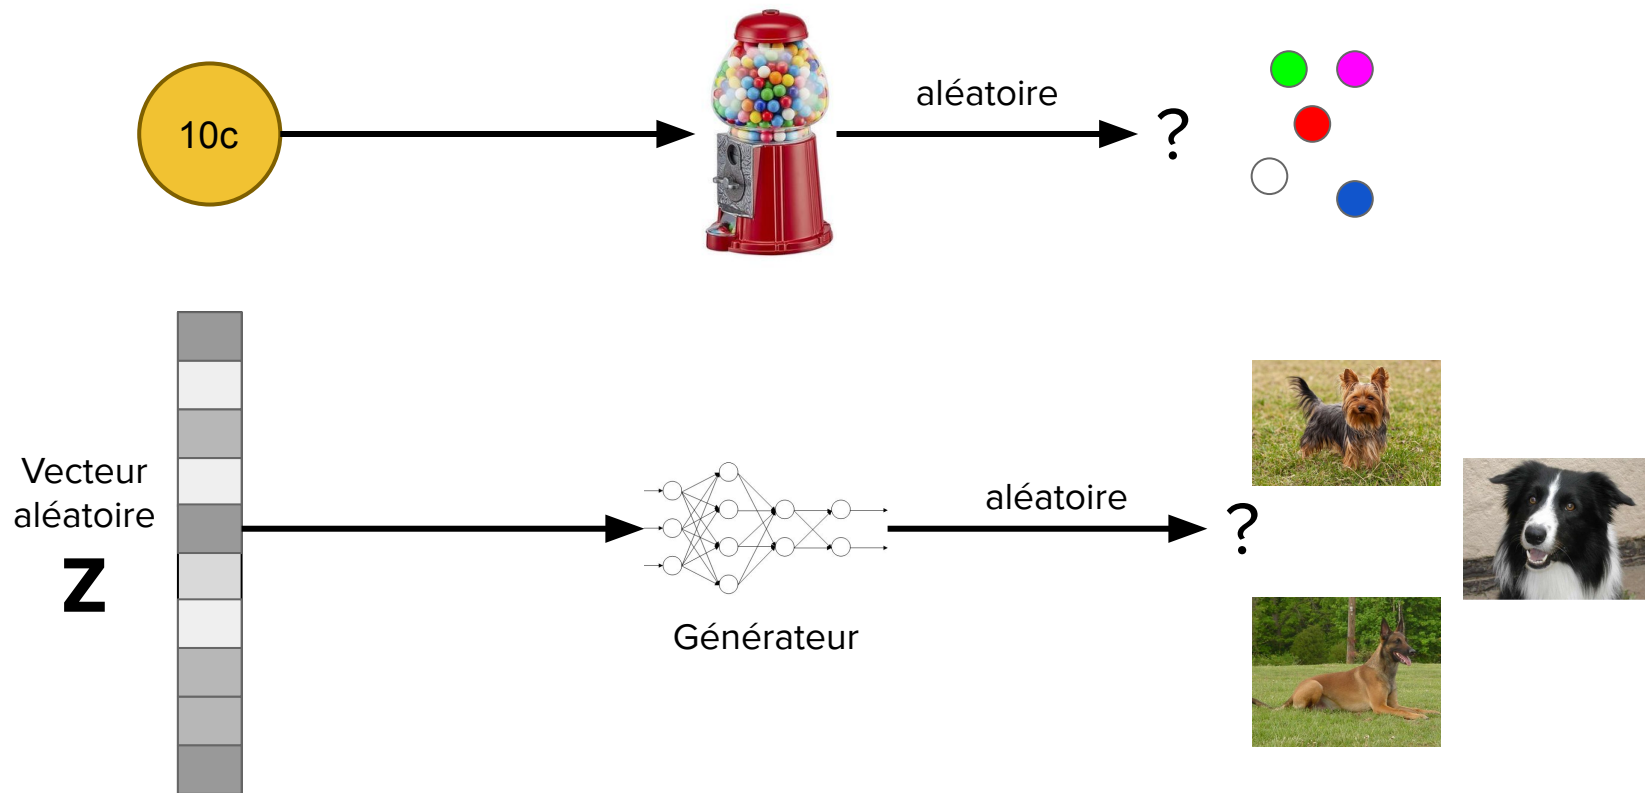


**quelques  
considérations ...**

# Conditional GANs





# Unconditional GANs





# Conditional GANs



# Conditional vs Unconditional GANs

## Conditional

- Génère la classe qu'on souhaite
- Les données d'entraînement doivent être annotées

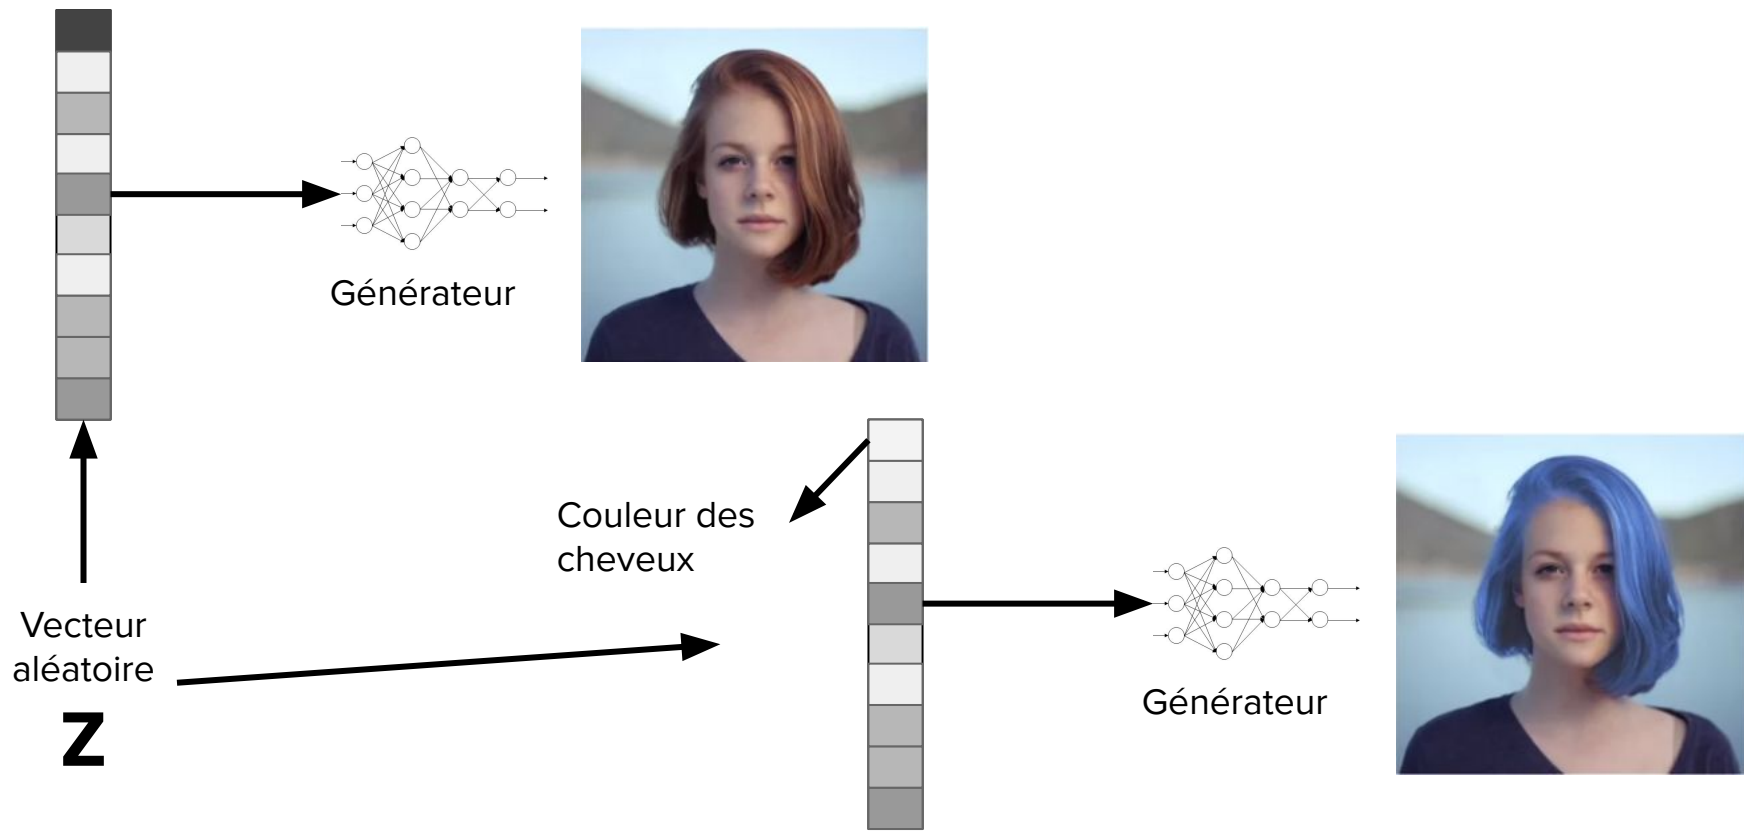
## Unconditional

- Génère une classe aléatoirement
- Les données d'entraînement ne doivent pas être libellées


# Controllable GANs



# Controllable GANs




# Z-space and controllable generation




Z-space avec les vecteurs aléatoires  $z$


$g(z_1)$



$g(z_3)$



$g(z_2)$



$g(z_3+d)$   
 $= g(z_4)$



# Controllable vs Conditional GANs

## Controllable

- Génère des images avec la caractéristique qu'on souhaite
- Les données d'entraînement ne doivent pas être annotées
- On manipule le vecteur  $\epsilon$  en entrée

## Conditional

- Génère la classe qu'on souhaite
- Les données d'entraînement doivent être annotées
- On concatène le vecteur  $\epsilon$  avec un vecteur de classe

**et pour la  
session 2**

sur la base d'un exemple, on rentrera dans le détail de l'implémentation d'un modèle :

- les limites
- les problèmes rencontrés et leurs solutions